

دانشگاه صنعتی امیرکبیر - پلی تکنیک تهران

دانشکده ریاضی و علوم کامپیوتر

گزارش فنی پروژه سوم داده کاوی

موتور تشخیص سرقت ادبی و اسناد مشابه

Semantic Duplicate & Near-Plagiarism Detection Engine

مدرس: دکتر فاطمه شاکری

اعضای گروه:

محمدحسین ایلخانی

صادق حیدری

رایین عسکری

نیم سال: بهار ۱۴۰۵

نسخه ۴,۰ - گزارش نهایی بهبود مدل، کالیبراسیون و تحلیل خطا

فهرست مطالب

۲	۱ چکیده
۲	۲ اهداف پروژه و معماری سامانه
۲	۱۰۲ گلوگاه مقایسه جفت‌به‌جفت (All-Pairs Bottleneck)
۳	۳ ساختار پیاده‌سازی و فایل‌های اصلی
۳	۴ پیش‌پردازش و شینگل‌سازی تطبیقی
۴	۱۰۴ حفظ ایست‌واژه‌های معنا ساز
۴	۲۰۴ شینگل‌سازی تطبیقی
۴	۵ مسیر اول: LSH، MinHash و جا‌کارد دقیق
۴	۱۰۵ شباهت جا‌کارد
۴	۲۰۵ امضای MinHash
۵	۳۰۵ بندبندی LSH
۵	۶ مسیر دوم: TF-IDF Weighted SimHash
۵	۱۰۶ نسخه ترکیبی (Hybrid SimHash)
۵	۷ شباهت کسینوسی TF-IDF
۶	۸ مدل کالیبره‌شده Calibrated Lexical Ensemble
۶	۱۰۸ ویژگی‌های پایه
۷	۲۰۸ آموزش رگرسیون لجستیک
۷	۳۰۸ جلوگیری از نشت داده
۷	۹ نتایج تجربی
۷	۱۰۹ ارزیابی نسخه دوم روی ۵۰۰۰ زوج
۸	۲۰۹ ارزیابی کالیبره‌شده روی بخش آزمون نگه‌داشته‌شده
۸	۱۰ تحلیل خطا
۸	۱۰۱ مثبت کاذب (False Positive)
۸	۲۰۱ منفی کاذب (False Negative)

۳۰۱۰ محدودیت تفسیر معنایی ۹

۱۱ رابط خط فرمان و بازتولیدپذیری ۹

۱۲ آزمون نرم‌افزار ۹

۱۳ جمع‌بندی ۱۰

۱ چکیده

در این پروژه، یک موتور خط فرمان برای تشخیص اسناد کپی شده، تقریباً تکراری و بازنویسی شده در متون فارسی و انگلیسی طراحی و پیاده‌سازی شد. دو مسیر الزامی پروژه، یعنی Shingling + MinHash + LSH و TF-IDF Weighted SimHash، از پایه و بدون استفاده از پیاده‌سازی آماده الگوریتم‌های اصلی ساخته شدند. سپس برای بهبود عملکرد روی متون کوتاه، شینگل‌سازی تطبیقی، حفظ ایست‌واژه‌های معناساز، Hybrid SimHash، شباهت کسینوسی TF-IDF و معیار Candidate Recall اضافه شدند.

در نسخه نهایی، یک مدل تکمیلی و شفاف با نام Calibrated Lexical Ensemble نیز پیاده‌سازی شد. این مدل ۱۵ ویژگی پایه و ۲۴ ویژگی درجه دوم و تعاملی را ترکیب می‌کند؛ در مجموع ۳۹ ویژگی. وزن‌ها با رگرسیون لجستیک و روش Newton/IRLS در خود پروژه و بدون scikit-learn آموزش داده می‌شوند. داده‌ها به صورت طبقه‌بندی شده به آموزش، اعتبارسنجی و آزمون تقسیم شدند؛ IDF فقط روی بخش آموزش محاسبه شد و آستانه تصمیم فقط روی بخش اعتبارسنجی انتخاب گردید. مدل نهایی روی بخش آزمون نگاه‌داشته شده به دقت 0.543، بازیابی 0.848، امتیاز $F_1 = 0.662$ و صحت 0.677 دست یافت.

۲ اهداف پروژه و معماری سامانه

هدف اصلی، ساخت سامانه‌ای بازتولیدپذیر برای سه سناریوی زیر است:

۱. مقایسه دو فایل متنی و ارائه امتیازهای شباهت؛
 ۲. جست‌وجوی اسناد مشابه در یک پوشه با کاهش مقایسه‌های غیرضروری؛
 ۳. ارزیابی تجربی روی دیتاست زوجی برچسب‌دار با معیارهای دقت، بازیابی، F_1 ، صحت و زمان اجرا.
- معماری نهایی از چهار لایه تشکیل شده است:

۱. مسیر لغوی مقیاس‌پذیر: Shingling + MinHash + LSH + exact Jaccard؛
 ۲. مسیر اثرانگشت فشرده: TF-IDF Weighted SimHash و نسخه ترکیبی آن؛
 ۳. مسیر شباهت برداری تکمیلی: TF-IDF Cosine با ویژگی‌های کلمه‌ای و کارا کتری؛
 ۴. لایه کالیبره شده: Calibrated Lexical Ensemble برای ترکیب چند سیگنال قابل توضیح.
- دو مسیر اول، هسته الزامی پروژه هستند و دو مسیر بعدی به عنوان توسعه تکمیلی و امتیازی افزوده شده‌اند.

۱.۲ گلوگاه مقایسه جفت‌به‌جفت (All-Pairs Bottleneck)

برای n سند، تعداد جفت‌های یگنا برابر است با:

$$\binom{n}{2} = \frac{n(n-1)}{2} = \mathcal{O}(n^2).$$

برای 400,000 سند، تعداد مقایسه‌ها تقریباً برابر با ۸۰ میلیارد است. بنابراین محاسبه مستقیم شباهت برای همه جفت‌ها در مقیاس بزرگ عملی نیست. LSH ابتدا فقط زوج‌های محتمل را به عنوان کاندید انتخاب می‌کند و محاسبه دقیق جاکارد روی همان مجموعه کوچک تر انجام می‌شود.

اصل الگوریتمی (Algorithmic Invariant)

LSH طبقه‌بند نهایی نیست؛ یک مولد کاندید است. بنابراین علاوه بر معیارهای طبقه‌بندی، باید Candidate Recall و میزان کاهش مقایسه‌ها نیز گزارش شوند.

۳ ساختار پیاده‌سازی و فایل‌های اصلی

کد به صورت ماژولار در پوشه src/plagiarism_engine سازمان‌دهی شده است:

- preprocessing.py: نرمال‌سازی، تشخیص زبان، توکن‌سازی، حذف تطبیقی ایست‌واژه و ساخت شینگل؛
- minhash.py: جاکارد دقیق، هش پایدار و ساخت امضای MinHash؛
- lsh.py: بندبندی، باکت‌بندی و تولید زوج‌های کاندید؛
- simhash.py: محاسبه TF-IDF و اثرانگشت ۶۴ بیتی؛
- bonus.py: Adaptive LSH، بن‌واژه‌ساز فارسی و Hybrid SimHash؛
- tfidf_cosine.py: بردار تنک TF-IDF و شباهت کسینوسی؛
- ensemble.py: استخراج ویژگی، رگرسیون لجستیک، کالیبراسیون، ذخیره و بارگذاری مدل؛
- evaluation.py: محاسبه معیارها، پیش‌بینی زوج‌ها و تحلیل خطا؛
- cli.py: دستورهای compare، corpus، pairs، bonus-eval و calibrate.

۴ پیش‌پردازش و شینگل‌سازی تطبیقی

متون ورودی در کلاس TextPreprocessor از مراحل زیر عبور می‌کنند:

۱. نرمال‌سازی یونیکد با قالب NFKC؛
۲. تبدیل نویسه‌های عربی رایج، مانند «ي» و «ل»، به معادل فارسی؛
۳. حذف کشیده، اعراب، پیوندهای وب، ایمیل‌ها و فاصله‌های اضافی؛
۴. تبدیل حروف لاتین به حالت کوچک؛
۵. تشخیص تقریبی زبان فارسی یا انگلیسی؛

۰۶. توکن‌سازی و حذف ایست‌واژه‌ها با سیاست تطبیقی؛

۰۷. ساخت شینگل‌های کلمه‌ای.

۱۰۴ حفظ ایست‌واژه‌های معناساز

در متن‌های کوتاه، حذف کلماتی مانند how، why، not و never می‌تواند معنای سؤال را تغییر دهد. در نسخه بهبودیافته، برای متن‌های کوتاه ایست‌واژه‌ها حفظ می‌شوند و منفی‌سازها نیز از فهرست حذف‌کار گذاشته شده‌اند.

۲۰۴ شینگل‌سازی تطبیقی

استفاده ثابت از شینگل سه‌کلمه‌ای برای سؤال‌های کوتاه باعث کاهش هم‌پوشانی می‌شود. سیاست جدید به صورت زیر است:

• تا ۶ توکن: ترکیب تک‌واژه و دوواژه؛

• ۷ تا ۱۲ توکن: ترکیب دوواژه و سه‌واژه؛

• متن‌های بلندتر: شینگل اصلی با اندازه ۳ تا ۵.

این سیاست، بازیابی مسیر لغوی را افزایش می‌دهد، بدون آنکه ساختار اصلی الگوریتم تغییر کند.

بیانیه تحلیل خطا (Error Analysis Axiom)

در متون کوتاه، حذف کورکورانه ایست‌واژه‌ها و استفاده از شینگل‌های بلند می‌تواند اطلاعات بیشتری از آنچه حذف می‌کند از بین ببرد. پیش‌پردازش باید با طول متن سازگار باشد.

۵ مسیر اول: LSH، MinHash و جا‌کارد دقیق

۱۰۵ شباهت جا‌کارد

برای دو مجموعه شینگل A و B ، شباهت جا‌کارد برابر است با:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}.$$

محاسبه مستقیم این معیار دقیق است، اما برای همه جفت‌ها هزینه درجه دوم دارد.

۲۰۵ امضای MinHash

برای هر شینگل ابتدا یک هش ۶۴ بیتی پایدار با BLAKE2b محاسبه می‌شود. سپس ۱۲۸ تابع هش از خانواده زیر به کار می‌روند:

$$h_i(x) = (a_i x + b_i) \bmod p,$$

که در آن $p = 2^{61} - 1$ و بذر تصادفی برابر ۴۲ است. شباهت تقریبی دو سند از نسبت مؤلفه‌های برابر دو امضا به دست می‌آید.

۳.۵ بندبندی LSH

امضا به b باند و هر باند به r سطر تقسیم می‌شود. احتمال کاندید شدن دو سند با شباهت واقعی s برابر است با:

$$P(\text{candidate}) = 1 - (1 - s^r)^b.$$

در ارزیابی ۵۰۰۰ زوجی نسخه دوم، از ۱۲۸ تابع هش و ۱۲۸ باند استفاده شد. این تنظیم باعث شد Candidate Recall به ۰.۸۴۴ برسد؛ یعنی بیش از ۸۴ درصد زوج‌های واقعاً مثبت وارد مرحله بررسی دقیق شدند. میزان کاهش مقایسه‌ها در این تنظیم ۰.۳۴۸ بود.

برای جلوگیری از مثبت کاذب مصنوعی، اسناد خالی یا بدون شینگل وارد ایندکس LSH نمی‌شوند؛ زیرا امضای مجموعه‌های خالی یکسان است.

۶ مسیر دوم: TF-IDF Weighted SimHash

وزن هر ویژگی از حاصل ضرب فرکانس زیرخطی واژه و فرکانس معکوس سند هموارشده محاسبه می‌شود:

$$\text{TF}(t, d) = 1 + \ln f_{t,d},$$

$$\text{IDF}(t) = \ln \left(\frac{N + 1}{\text{df}(t) + 1} \right) + 1.$$

برای هر ویژگی، هش ۶۴ بیتی ساخته می‌شود. وزن ویژگی در ابعادی که بیت هش برابر ۱ است اضافه و در ابعادی که بیت برابر صفر است کم می‌شود. علامت مقدار نهایی هر بعد، بیت اثرانگشت را تعیین می‌کند. فاصله دو اثرانگشت با فاصله همینگ محاسبه می‌شود:

$$H(x, y) = \text{popcount}(x \oplus y).$$

۱.۶ نسخه ترکیبی (Hybrid SimHash)

نسخه ترکیبی علاوه بر تک‌واژه‌ها، از سه‌گرام‌های کاراکتری نیز استفاده می‌کند. این ویژگی در برابر غلط املایی، تغییر شکل کلمات و تفاوت‌های جزئی نگارشی مقاوم‌تر است. در ارزیابی ۵۰۰۰ زوجی، با آستانه همینگ ۲۲، این روش به دقت ۰.۴۹۸، بازیابی ۰.۸۲۳ و $F_1 = 0.621$ رسید.

۷ شباهت کسینوسی TF-IDF

در این توسعه، برای هر سند بردار تک TF-IDF با تک‌واژه‌ها و سه‌گرام تا پنج‌گرام کاراکتری ساخته می‌شود. شباهت دو سند از رابطه زیر به دست می‌آید:

$$\cos(\theta) = \frac{\mathbf{x} \cdot \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

این روش برخلاف SimHash اطلاعات بردار را به ۶۴ بیت فشرده نمی‌کند؛ بنابراین بخشی از جزئیات واژگانی و زیرواژه‌ای حفظ می‌شود. روی ۵۰۰۰ زوج با آستانه 0.32، مقدار F_1 برابر 0.660 به دست آمد.

۸ مدل کالیبره‌شده Calibrated Lexical Ensemble

برای ترکیب نقاط قوت سیگنال‌های مختلف، یک مدل قابل توضیح افزوده شد. این مدل جایگزین مسیرهای اصلی نیست، بلکه خروجی‌های لغوی و ساختاری را در یک تصمیم کالیبره‌شده ادغام می‌کند.

۱۰۸ ویژگی‌های پایه

۱۵ ویژگی پایه عبارت‌اند از:

۰۱. کسینوس TF-IDF تک‌واژه‌ای؛

۰۲. کسینوس TF-IDF تک‌واژه و دوواژه؛

۰۳. کسینوس TF-IDF کاراکتری ۳ تا ۵ گرمی؛

۰۴. جا کارد توکن‌ها؛

۰۵. ضریب هم‌پوشانی؛

۰۶. نسبت طول متن‌ها؛

۰۷. یکسان بودن کلمه پرسشی؛

۰۸. متفاوت بودن کلمه پرسشی؛

۰۹. اختلاف در وجود منفی ساز؛

۰۱۰. شباهت ترتیب کاراکترها؛

۰۱۱. شباهت توکن‌های مرتب‌شده؛

۰۱۲. جا کارد دوواژه‌ها؛

۰۱۳. یکسان بودن اولین توکن؛

۰۱۴. نسبت پیشوند مشترک؛

۰۱۵. یکسان بودن کامل متن نرمال‌شده.

با افزودن توان دوم ۱۰ ویژگی پیوسته و ۱۴ برهم‌کنش منتخب، تعداد کل ویژگی‌ها به ۳۹ می‌رسد.

۲۰۸ آموزش رگرسیون لجستیک

احتمال تکراری بودن یک زوج با تابع سیگموئید محاسبه می‌شود:

$$P(y = 1 | \mathbf{x}) = \sigma(w_0 + \mathbf{w}^T \mathbf{x}), \quad \sigma(z) = \frac{1}{1 + e^{-z}}.$$

وزن‌ها با روش Newton/IRLS و منظم‌سازی L_2 در خود پروژه آموزش داده شدند. از مدل آماده scikit-learn استفاده نشده است.

۳۰۸ جلوگیری از نشت داده

۱۵ هزار زوج به صورت طبقه‌بندی شده و قطعی تقسیم شدند:

• ۸۹۹۹ زوج آموزش؛

• ۲۹۹۹ زوج اعتبارسنجی؛

• ۳۰۰۲ زوج آزمون.

IDF و وزن‌های مدل فقط با داده آموزش محاسبه شدند. آستانه تصمیم فقط روی اعتبارسنجی انتخاب شد و برابر 0.43982 بود. بخش آزمون تا پایان فرایند برای ارزیابی نهایی کنار گذاشته شد.

مدل آموزش دیده همراه با وزن‌ها، میانگین و انحراف معیار ویژگی‌ها، آستانه و جداول IDF ذخیره می‌شود. مسیر فایل مدل به صورت زیر است:

outputs/calibrated_ensemble.json

این مدل در دستورهای compare و corpus قابل استفاده است.

۹ نتایج تجربی

۱۰۹ ارزیابی نسخه دوم روی ۵۰۰۰ زوج

جدول ۱: نتایج روش‌های بهبودیافته روی ۵۰۰۰ زوج Quora

کاهش مقایسه	Candidate Recall	صحت	F_1	بازیابی	دقت	روش
0.348	0.844	0.646	0.591	0.668	0.529	MinHash+LSH+Jaccard
0.000	-	0.615	0.621	0.823	0.498	Hybrid SimHash
0.000	-	0.651	0.660	0.885	0.526	TF-IDF Cosine

این جدول نشان می‌دهد شینگل تطبیقی و افزایش حساسیت LSH، بازیابی مسیر اول را نسبت به نسخه اولیه افزایش داده است. کسینوس TF-IDF نیز بالاترین F_1 این آزمایش را دارد، اما برخلاف LSH همه زوج‌ها را بررسی می‌کند.

۲۰۹ ارزیابی کالیبره‌شده روی بخش آزمون نگه‌داشته‌شده

جدول ۲: مقایسه روی بخش آزمون مستقل با ۳۰۰۲ زوج

روش	دقت	بازیابی	F_1	صحت
Character TF-IDF Cosine	0.509	0.821	0.628	0.638
Token Jaccard	0.503	0.877	0.639	0.631
Calibrated Lexical Ensemble	0.543	0.848	0.662	0.677

در اعتبارسنجی، مدل ترکیبی به $F_1 = 0.682$ رسید و آستانه آن همان‌جا انتخاب شد. نتیجه آزمون $F_1 = 0.662$ است و به دلیل جداسازی آزمون، برآورد واقع‌بینانه‌تری از تعمیم مدل محسوب می‌شود.

نتیجه کلیدی (Key Takeaway)

مدل ترکیبی نسبت به بهترین خط پایه آزمون، یعنی جا کارد توکنی با $F_1 = 0.639$ ، امتیاز F_1 را به 0.662 و صحت را از 0.631 به 0.677 افزایش داد. این بهبود بدون استفاده از مدل آماده یادگیری ماشین یا مدل زبانی عمیق حاصل شده است.

۱۰ تحلیل خطا

۱۰.۱۰ مثبت کاذب (False Positive)

نمونه زیر فقط در منفی ساز تفاوت دارد:

• “How can I make money online?”

• “How can I not make money online?”

شباهت واژگانی زیاد است، اما معنای دو جمله متفاوت است. ویژگی negation mismatch در مدل ترکیبی برای کاهش چنین خطاهایی اضافه شد.

۲۰۱۰ منفی کاذب (False Negative)

نمونه زیر بازنویسی معنایی با هم‌پوشانی لغوی کم است:

• “What is the best way to lose weight?”

• “How can I reduce body fat?”

روش‌های صرفاً لغوی ممکن است این زوج را از دست بدهند. ویژگی‌های کاراکتری و ساختاری بخشی از این ضعف را کاهش می‌دهند، اما درک کامل چنین بازنویسی‌هایی معمولاً به نمایش‌های معنایی عمیق‌تر نیاز دارد.

۳.۱۰ محدودیت تفسیر معنایی

نام پروژه بر تشابه معنایی تأکید دارد، اما روش‌های حاضر عمدتاً لغوی، زیرواژه‌ای و ساختاری هستند. مدل ترکیبی نیز یک مدل زبانی عمیق نیست. بنابراین عملکرد آن روی بازنویسی‌هایی که هیچ واژه یا الگوی ساختاری مشترکی ندارند محدود باقی می‌ماند.

۱۱ رابط خط فرمان و بازتولیدپذیری

دستور آموزش و ارزیابی مدل کالیبره‌شده:

```
1 python -m plagiarism_engine.cli calibrate \
2   --pairs data/raw/quora/train.csv \
3   --text-col-a question1 \
4   --text-col-b question2 \
5   --label-col is_duplicate \
6   --id-col id \
7   --adaptive-short-text \
8   --output outputs/calibrated_metrics.csv \
9   --predictions-output outputs/calibrated_predictions.csv \
10  --model-output outputs/calibrated_ensemble.json
```

استفاده از مدل ذخیره‌شده برای مقایسه دو فایل:

```
1 python -m plagiarism_engine.cli compare \
2   --file-a data/sample_corpus/doc_01.txt \
3   --file-b data/sample_corpus/doc_02.txt \
4   --ensemble-model outputs/calibrated_ensemble.json \
5   --output outputs/two_file_compare_ensemble.json
```

بذر تصادفی، توابع هش پایدار و تقسیم قطعی داده‌ها باعث می‌شوند نتایج قابل بازتولید باشند. فایل‌های خروجی شامل متریک‌ها، پیش‌بینی تک‌تک زوج‌ها و مدل ذخیره‌شده هستند.

۱۲ آزمون نرم‌افزار

مجموعه آزمون‌ها شامل پیش‌پردازش فارسی و انگلیسی، جا‌کارد، MinHash، LSH، SimHash، کسینوس TF-IDF، شینگل تطبیقی، مدل ترکیبی، ذخیره و بارگذاری مدل و دستورهای خط فرمان است. در نسخه نهایی، هر ۲۰ آزمون با موفقیت اجرا شده‌اند.

۱۳ جمع‌بندی

پروژه ابتدا دو مسیر کلاسیک و الزامی تشخیص شباهت را از صفر پیاده‌سازی کرد. سپس با شینگل‌سازی تطبیقی، حفظ کلمات معناساز، Hybrid SimHash، کسینوس TF-IDF و معیار Candidate Recall بهبود یافت. در مرحله نهایی، مدل Calibrated Lexical Ensemble با ۳۹ ویژگی، تقسیم صحیح آموزش و آزمون و کالیبراسیون آستانه اضافه شد. این مدل روی آزمون مستقل به $F_1 = 0.662$ و صحت 0.677 رسید و در عین حال تفسیرپذیر، سبک و قابل استفاده از طریق رابط خط فرمان باقی ماند.

مراجع

- [۱] فاطمه شاکری، «راهنمای پروژه سوم درس داده‌کاوی: موتور تشخیص سرقت ادبی و اسناد مشابه»، دانشگاه صنعتی امیرکبیر، بهار ۱۴۰۵.
- [۲] فاطمه شاکری، «جزوه الگوریتم Locality Sensitive Hashing»، دانشگاه صنعتی امیرکبیر.
- [۳] فاطمه شاکری، «جزوه متن کاوی»، دانشگاه صنعتی امیرکبیر.
- [۴] Quora Question Pairs Dataset، duplicate-question for used subset evaluation، detection.